


Multivariable Correlation

C_n^2 个相关系数

$$X = (X_1, X_2, \dots, X_n)^T \text{ Joint Distribution?} \Rightarrow \text{Correlation Matrix}$$

$$R_X = E(XX^T) \quad R_{X(i,j)} = E(X_i, X_j) \quad R_X = R_X^T$$

① Decorrelation (Whitening) 去相关性 / 白化 $A \in \mathbb{R}^{n \times n}$, $Y = AX \in \mathbb{R}^n$

$$E(Y_i, Y_j) = 0 \quad (i \neq j)$$

线性变换, 去对角外相关

$$\Rightarrow R_Y = E(AX)(AX)^T = A E(XX^T) A^T = A R_X A^T$$

矩阵特征分解

$$R_X = \sum_{k=1}^n \lambda_k V_k V_k^T = U \Lambda V^T, \quad U = (U_1, \dots, U_k), \quad U \cdot U^T = U^T \cdot U = I$$

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n), \quad \lambda_k > 0, \quad \forall k$$

$$\Rightarrow U^T R_X U = \Lambda \quad \Rightarrow \boxed{A = U^T} \quad \star$$

正交损失最小

② Principal Component Analysis (PCA)

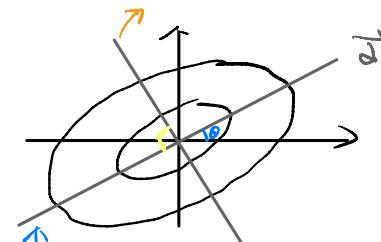
$$\alpha \in \mathbb{R}^n, \quad E \|\text{Proj}_{\alpha} X\|^2 = E \left\| \frac{\alpha^T X}{\|\alpha\|} \cdot \alpha \right\|^2$$

$$\begin{aligned} \text{方差} &= \frac{E |\alpha^T X|^2}{\|\alpha\|^4} \cdot \|\alpha\|^2 = E \left(\frac{\alpha^T}{\|\alpha\|} \cdot X \right)^2 \\ \text{有最大方差} &\end{aligned}$$

找 α

$$\max_{\alpha} E \|\text{Proj}_{\alpha} X\|^2 = \max_{\alpha} E \left(\frac{\alpha^T}{\|\alpha\|} X \right)^2$$

$$\Leftrightarrow \max_{\alpha} E (\alpha^T X)^2 \quad \text{s.t. } \|\alpha\| = 1 \quad \text{约定投影到 \alpha 上的范数为 1}$$



在这根轴上分布比较开,
方差比较大

(Dimensional Deduction)
Compression

$$E(\alpha^T X)^2 = E(\alpha^T X)(X^T \alpha) = \alpha^T E(X X^T) \alpha = \alpha^T R_X \alpha$$

$$\max_{\alpha} \alpha^T R_X \alpha, \quad \text{s.t. } \|\alpha\| = 1$$

$$L(\alpha, \lambda) = \alpha^T R_X \alpha + \lambda (\|\alpha\|^2 - 1)$$

求导

$$\nabla_{\alpha} L(\alpha, \lambda) = 2 \cdot R_X \cdot \alpha - 2\lambda \alpha = 0 \Leftrightarrow R_X \alpha = \lambda \alpha$$

$$\max_{\alpha} \alpha^T R_X \alpha = \lambda \alpha^T \alpha = \lambda \Rightarrow \text{Eigen vector w.r.t largest Eigenvalue}$$

特征值最大

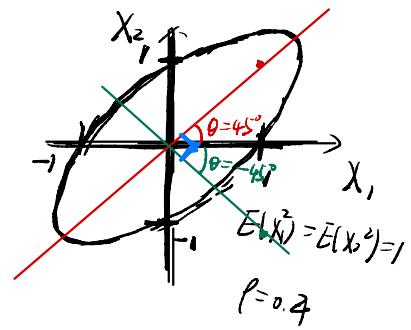
对称矩阵特征向量性质: 不同特征值对应的特征向量正交

从特征向量偏移角度 θ 分析相关性

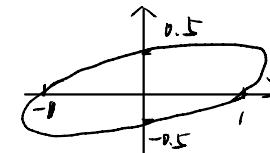
$$E(X_1) = E(X_2) = 0, \quad E(X_1^2) = E(X_2^2) = 1, \quad E(X_1 X_2) = \rho, \quad X = (X_1, X_2)^T$$

$$R_X = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} \Rightarrow \lambda_1 = 1+\rho, \lambda_2 = 1-\rho \Rightarrow U_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}_{45^\circ}, \quad U_2 = \begin{pmatrix} 1 \\ -1 \end{pmatrix}_{-45^\circ}$$

决定角度的是方差
不是相关系数 ρ



ρ 大了相关性强, X_1 与 X_2 “距离”更近, “相似”更广



$$E(X_1) = 1 \quad E(X_2) = 0.5 \quad \rho = 0.6$$

$$\textcircled{3} \text{ Expansion } Y = AX \Rightarrow X = A^{-1}Y \Rightarrow X = U \cdot Y = \sum_{k=1}^n U_k \cdot y_k$$

$$U_i^T U_j = 0 \quad (i \neq j)$$

$$E(Y_i Y_j) = 0 \quad (i \neq j) \quad (\text{Biorthogonal Expansion})$$

Orthogonal

Orthogonal

系数有正交性

基也有正交性

Karhunen-Loeve Expansion (K-L 展开)

exp(iwkt) \rightarrow 一定区域正交, 但系数正交性无法保证

$$X(t) = \sum_{k=-\infty}^{\infty} \alpha_k \phi_k(t)$$

展开, 将随机性和过程性解耦

Assume $\{\phi_k\}$ orthogonal

寻找比傅里叶展开(单正交)更高级的

$$\text{假定} \{\phi_k\} \text{ 在区间 I 上) } \exists - \int_I \phi_k^2(t) dt = 1$$

双正交展开(基正交 + 系数也正交)

$$\int_I \phi_i(t) \phi_j(t) dt = 0$$

$$\alpha_k = \int_I X(t) \phi_k(t) dt$$

$$\Rightarrow E(\alpha_i \alpha_j) = E\left(\int_I X(t) \phi_i(t) dt \int_I X(s) \phi_j(s) ds\right)$$

$$= \int_I \int_I E(X(t) X(s)) \phi_i(t) \phi_j(s) dt ds = \int_I \int_I R_X(t, s) \phi_i(t) \phi_j(s) dt ds = 0 \quad (i \neq j)$$

1. 积分看作求和 2. 二元函数看作矩阵 3. 一元函数看作变量

$$\Rightarrow \sum_m \sum_n R_X(m, n) \phi_i(m) \phi_j(n)$$

$$\Phi_i^T R_X \Phi_j = \Phi_i^T (\lambda_j \Phi_j) = 0 \quad \xrightarrow{\text{连续版本下特征函数}}$$

$$\int_I R_X(t, s) \phi_i(s) ds = \lambda_i \phi_i(t) \quad \xrightarrow{\text{Integral Equation}}$$

$$\left\{ \sum_n R_X(m, n) \phi_i(n) = \lambda_i \phi_i(m) \Leftrightarrow R_X \Phi_i = \lambda_i \Phi_i \right.$$

对称矩阵特征向量正交(上证)

1. Karhunen-Loève 展开

K-L 展开用于将一个随机过程 $X(t)$ 以一组正交基函数 $\{\phi_k(t)\}$ 进行展开：

$$X(t) = \sum_{k=1}^{\infty} \alpha_k \phi_k(t)$$

其中 $\{\phi_k(t)\}$ 是一组正交基函数，而 α_k 是对应的随机系数。

2. 计算系数 α_k

为了计算 α_k ，我们利用正交投影的思想。

1. 两边同时与 $\phi_k(t)$ 相乘并在定义域 I 上积分：

$$\int_I X(t) \phi_k(t) dt = \int_I \left(\sum_{j=1}^{\infty} \alpha_j \phi_j(t) \right) \phi_k(t) dt$$

2. 交换求和与积分（在合适的数学条件下是成立的）：

$$\sum_{j=1}^{\infty} \alpha_j \int_I \phi_j(t) \phi_k(t) dt$$

3. 利用正交性：由于 $\{\phi_k(t)\}$ 是一组正交基，满足：

$$\int_I \phi_j(t) \phi_k(t) dt = \delta_{jk}$$

其中 δ_{jk} 是 Kronecker Delta（当 $j = k$ 时取 1，否则取 0）。因此，只有当 $j = k$ 时，积分项不为零，所有其他项都消失，得到：

$$\alpha_k \cdot 1 = \int_I X(t) \phi_k(t) dt$$

3. 结论

因此，我们得到了 K-L 展开的系数公式：

$$\alpha_k = \int_I X(t) \phi_k(t) dt$$

这说明 α_k 是随机过程 $X(t)$ 在基函数 $\phi_k(t)$ 方向上的投影（积分形式）。这个公式的意义在于，它可以用来分析和表示随机过程的主要成分，并且对于信号处理、模式识别和数据降维（如 PCA）具有重要应用。

直观解释

如果你熟悉傅里叶级数展开，这个公式的作用与傅里叶级数的系数计算类似：

$$c_n = \int X(t) e^{-jn\omega t} dt$$

它表示的是在正交基 $e^{-jn\omega t}$ 上的投影。而 K-L 展开则是用一组适合 $X(t)$ 的最佳正交基来进行展开，因此有类似的投影系数计算方式。

总结

α_k 可以用 $X(t) \phi_k(t)$ 的积分形式表达，因为：

1. K-L 展开是一种基函数展开，其中 $\phi_k(t)$ 是一组正交基。
2. 利用正交性，投影计算中所有非相关项都消失，只留下对应的系数。
3. 这个积分形式本质上是计算 $X(t)$ 在基函数 $\phi_k(t)$ 方向上的投影。

$$I = \left[-\frac{T}{2}, \frac{T}{2} \right]$$

$$\int_{-\frac{T}{2}}^{\frac{T}{2}} R_X(t-s) \phi_R(s) ds = \boxed{J_R(\phi_R(t))} \quad \phi_R(t) = \exp(i \frac{2k\pi}{T} t)$$

$$\begin{aligned} & \int_{-\frac{T}{2}}^{\frac{T}{2}} R_X(t-s) \exp(i \frac{2k\pi}{T} s) ds \quad ds = -ds \\ &= - \int_{t-\frac{T}{2}}^{t+\frac{T}{2}} R_X(s') \exp(-i \frac{2k\pi}{T} s') ds' \exp(i \frac{2k\pi}{T} t) \quad R_X(t) = R_X(t+T) \end{aligned}$$

① W.S.S. $R_X(T) = R_X(T+T)$

$$X(t) = \sum_{k=-\infty}^{+\infty} \alpha_k \exp(i \frac{2k\pi}{T} t) \quad (\text{双正交 / Bi-Orthogonal})$$

② $T \rightarrow \infty$

$$\begin{aligned} X(t) &\stackrel{?}{=} \int_{-\infty}^{+\infty} \alpha(w) \exp(iwt) dw \\ &= \int_{-\infty}^{+\infty} \exp(iwt) dF_X(w) \end{aligned}$$

Stieltjes Integration

$$\int f(x) dg(x) \Leftarrow \sum_k f(x_k) \Delta g(x_k)$$

$$\Delta g(x_k) = g(x_k) - g(x_{k-1})$$

Riemann

$$\int f(x) dx \Leftarrow \sum_k f(x_k) \Delta x_k$$

$$X(t) = \int_{-\infty}^{+\infty} \exp(iwt) dF_X(w)$$

随机过程的谱表示
Spectral Representation

→ 对应 α_k (双正交)

$$E(dF_X(w_1) \overline{dF_X(w_2)}) = 0 \quad \downarrow w_1 = w_2$$

$$E|dF_X(w)|^2 = \frac{1}{\pi} S_X(w) dw$$

$$R_X(t+s) = R_X(t-s) = E(X(t) \overline{X(s)})$$

$$= E \left(\int_{-\infty}^{+\infty} \exp(iw_1 t) dF_X(w_1) \int_{-\infty}^{+\infty} \exp(iw_2 s) dF_X(w_2) \right)$$

$$= \iint \exp(i(w_1 t + w_2 s)) E(dF_X(w_1) \overline{dF_X(w_2)})$$

$$= \int \exp(iw(t-s)) \boxed{E|dF_X(w)|^2}$$

$$= \boxed{\frac{1}{2\pi}} \int \exp(iw(t-s)) S_X(w) dw \quad (\text{功率谱密度傅立叶反变换})$$

